## K-Means

#### Jimena Isaura Medina Padilla

6/3/2022

1.-Cargar la matriz de datos.

```
X<-as.data.frame(state.x77)</pre>
```

## Transformación de datos

1.- Transformación de las variables x1,x3 y x8 con la función de logaritmo.

```
X[,1]<-log(X[,1])
colnames(X)[1]<-"Log-Population"

X[,3]<-log(X[,3])
colnames(X)[3]<-"Log-Illiteracy"

X[,8]<-log(X[,8])
colnames(X)[8]<-"Log-Area"</pre>
```

#### Metodo k-means

1.- Separación de filas y columnas.

```
dim(X)

## [1] 50 8

n<-dim(X)[1]
p<-dim(X[2])</pre>
```

2.-Estandarización univariante.

```
X.s<-scale(X)
```

3.- Algoritmo k-medias (3 grupos) cantidad de subconjuntos aleatorios que se escogen para realizar los calculos de algoritmo.

```
Kmeans.3<-kmeans(X.s, 3, nstart=25)</pre>
```

### Centroides

Kmeans.3\$centers

```
##
   Log-Population
                 Income Log-Illiteracy    Life Exp
                                                     HS Grad
                                             Murder
## 1
      -0.7900149 0.2080926
                         ## 2
       0.5693805 0.5486843
                         1.31921387 -1.0778757 1.10983501 -1.3566922
## 3
       0.2360549 -1.2266128
       Frost Log-Area
## 1 0.8803670 0.4093602
## 2 -0.3291597 -0.4878988
## 3 -0.7719510 0.1991243
```

## Cluster de pertenencia

Kmeans.3\$cluster

##	Alabama	Alaska	Arizona	Arkansas	California
##	3	1	2	3	2
##	Colorado	Connecticut	Delaware	Florida	Georgia
##	1	2	2	2	3
##	Hawaii	Idaho	Illinois	Indiana	Iowa
##	2	1	2	2	1
##	Kansas	Kentucky	Louisiana	Maine	Maryland
##	1	3	3	1	2
##	Massachusetts	Michigan	Minnesota	Mississippi	Missouri
##	2	2	1	3	2
##	Montana	Nebraska	Nevada	New Hampshire	New Jersey
##	1	1	1	1	2
##	New Mexico	New York	North Carolina	North Dakota	Ohio
##	3	2	3	1	2
##	Oklahoma	Oregon	Pennsylvania	Rhode Island	South Carolina
##	2	1	2	2	3
##	South Dakota	Tennessee	Texas	Utah	Vermont
##	1	3	3	1	1
##	Virginia	Washington	West Virginia	Wisconsin	Wyoming
##	2	2	3	1	1

4.- SCDG

```
SCDG<-sum(Kmeans.3$withinss)
SCDG</pre>
```

## [1] 203.2068

#### 5.- Clusters

```
cl.kmeans<-Kmeans.3$cluster</pre>
```


cl.kmeans

##	Alabama	Alaska	Arizona	Arkansas	California
##	3	1	2	3	2
##	Colorado	Connecticut	Delaware	Florida	Georgia
##	1	2	2	2	3
##	Hawaii	Idaho	Illinois	Indiana	Iowa
##	2	1	2	2	1
##	Kansas	Kentucky	Louisiana	Maine	Maryland
##	1	3	3	1	2
##	Massachusetts	Michigan	Minnesota	Mississippi	Missouri
##	2	2	1	3	2
##	Montana	Nebraska	Nevada	New Hampshire	New Jersey
##	1	1	1	1	2
##	New Mexico	New York	North Carolina	North Dakota	Ohio
##	3	2	3	1	2
##	Oklahoma	Oregon	Pennsylvania	Rhode Island	South Carolina
##	2	1	2	2	3
##	South Dakota	Tennessee	Texas	Utah	Vermont
##	1	3	3	1	1
##	Virginia	Washington	West Virginia	Wisconsin	Wyoming
##	2	2	3	1	1

6.- Scatter plot con la division de grupos obtenidos (se utiliza la matriz de datos centrados).


```
col.cluster<-c("yellow", "orange", "green")[cl.kmeans]
pairs(X.s, col=col.cluster, main="k-means", pch=19)</pre>
```

### k-means



# Visualización con las dos componentes principales

## Dos primeras componentes principales



These two components explain 62.5 % of the point variability.

### Silhouette

Representación grafica de la eficacia de clasificación de una observacion dentro de un grupo.


1.- Generación de los calculos

```
dist.Euc<-dist(X.s, method = "euclidean")
Sil.kmeans<-silhouette(cl.kmeans, dist.Euc)</pre>
```

2.- Generación del gráfico

```
plot(Sil.kmeans, main="Silhouette for k-means",
col="slateblue1")
```

# Silhouette for k-means



Average silhouette width: 0.28